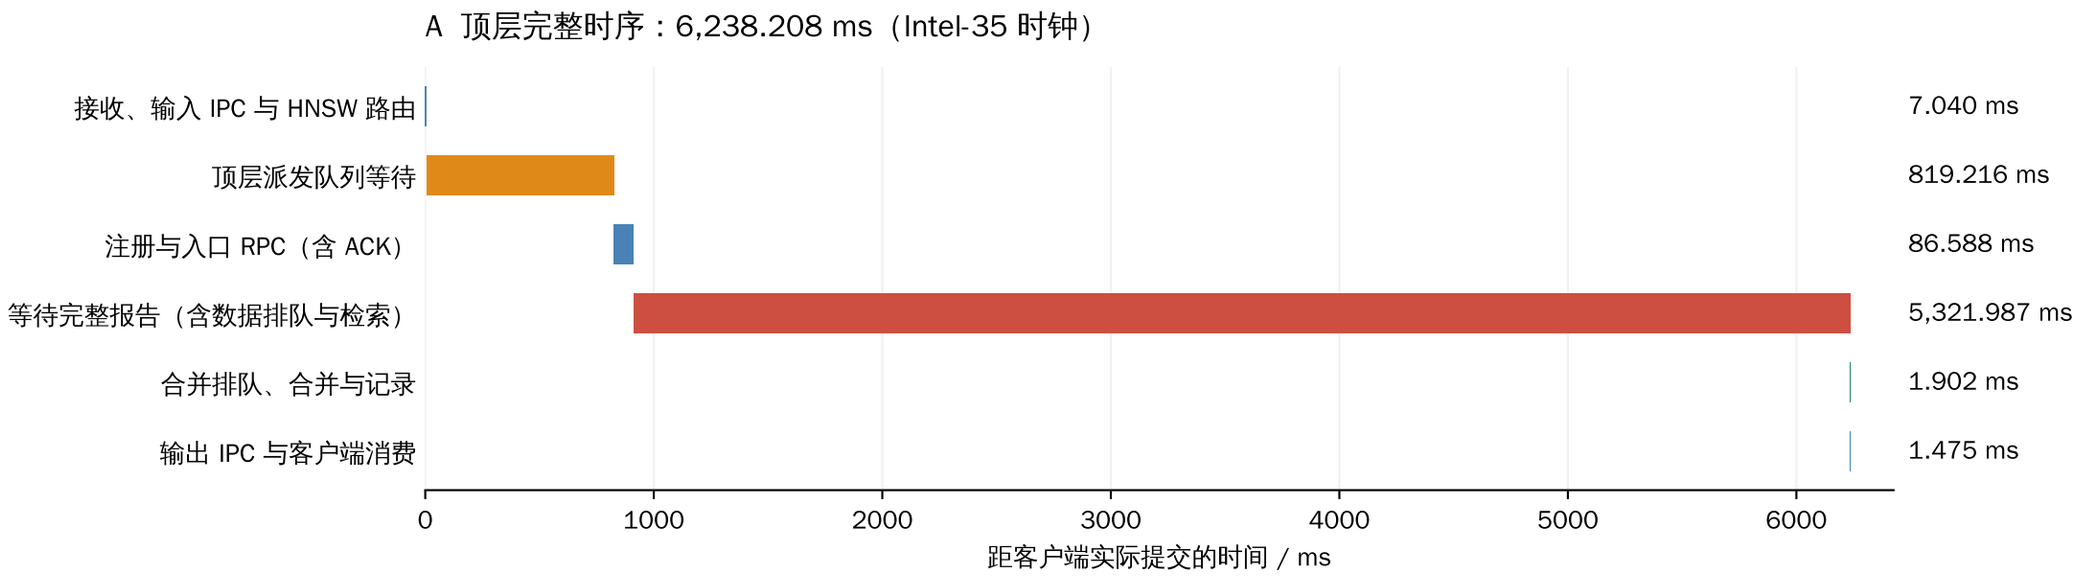
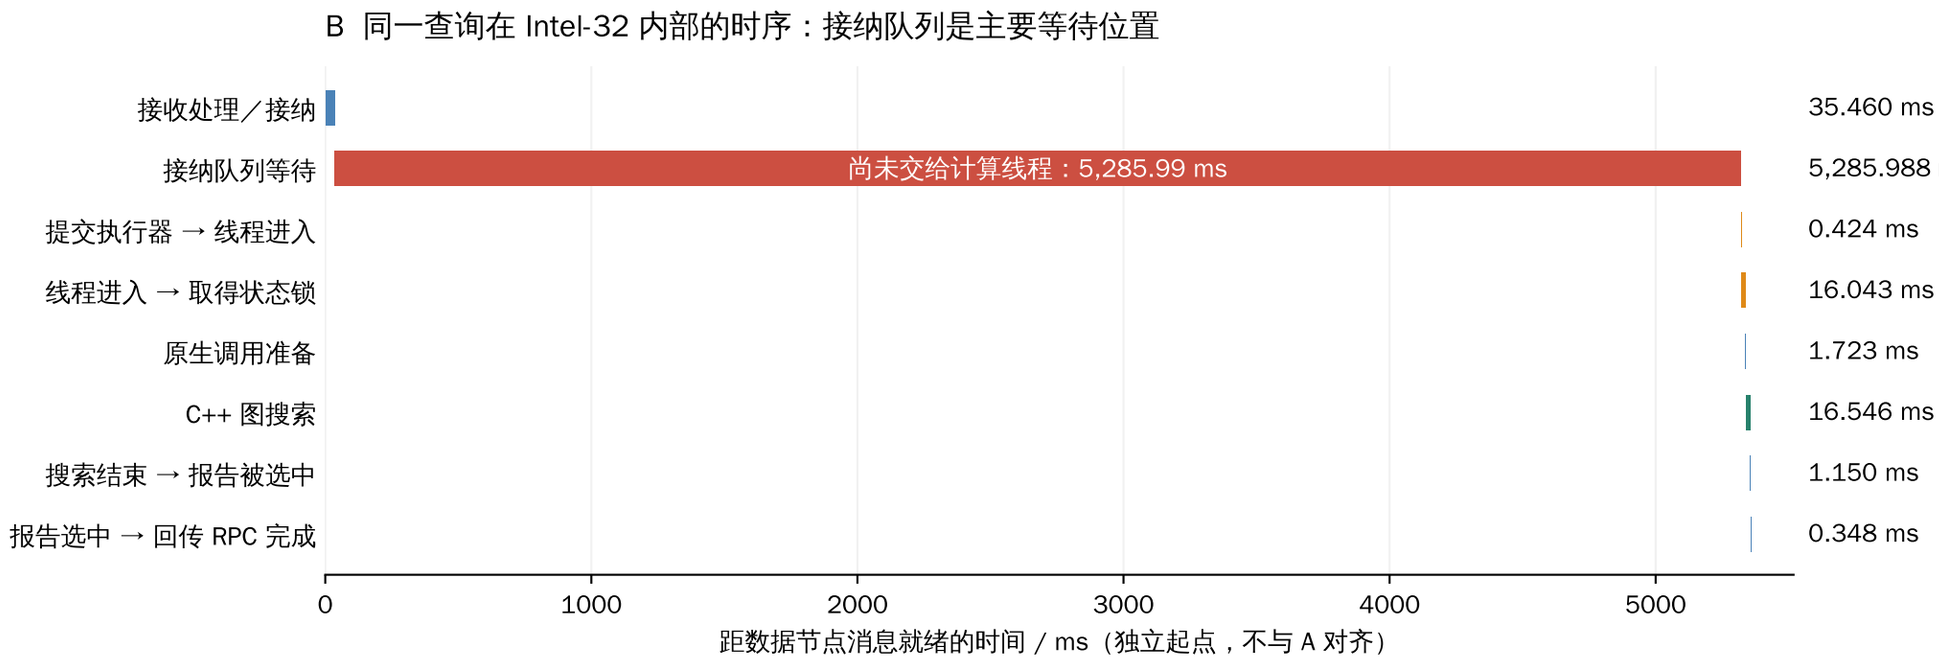
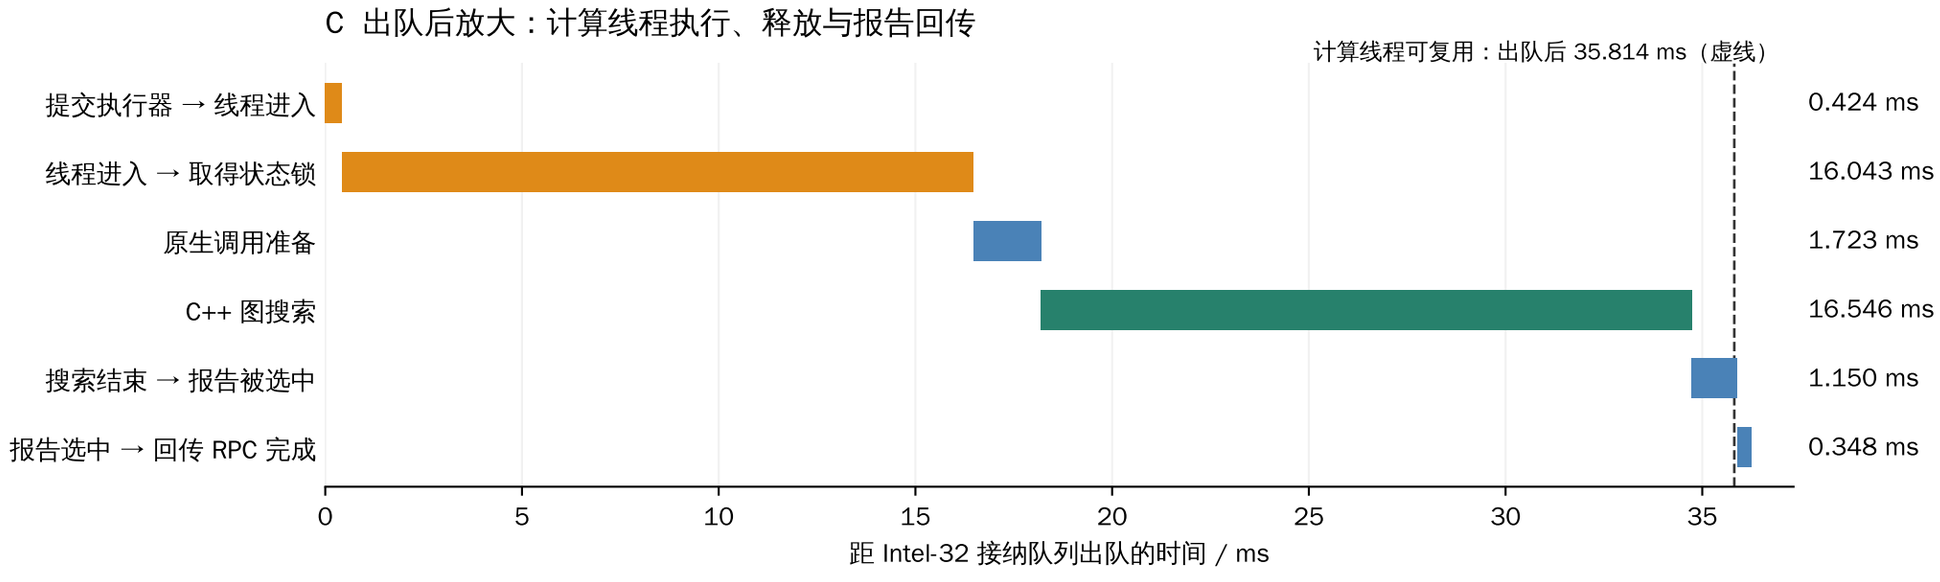
等待发生在哪里？查询 458421 · 第 88444 号任务 · Recall@10=100%

最新 control_capacity 连续测试：100000 请求，并发 256，三机各 32 个查询线程，预算 200
选样规则：在保留完整时间戳的单分支查询中，选择延迟最接近全程 p99 的请求；这是尾延迟样本。







A 是互斥的端到端阶段；B/C 是同一查询的数据节点内部观测，不可与 A 重复相加。
等待报告包含数据排队、检索和回传，不等于纯网络时间。锁前区间可能含线程调度，不能仅据时长断定忙等。